

合肥工业大学

《人工智能基础》课程 设计报告

设计题目： 基于改进遗传算法的含分布式电源
 电网无功优化

小组成员及学号： 薛晓阳
 2023216313

专业班级： 电气 23-3 班

2025 年 12 月 29 日

Contents

1 引言	3
1.1 研究背景与意义	3
1.2 研究现状	4
1.3 人工智能算法	5
2 模型介绍	6
2.1 传统遗传算法	6
2.1.1 进行问题编码	6
2.1.2 构造初始种群	6
2.1.3 建立适应度函数	7
2.1.4 执行选择、交叉、变异操作	7
2.1.5 更新种群并迭代	7
2.2 改进遗传算法	8
2.2.1 混合编码	8
2.2.2 适应度函数改进	9
2.2.3 最优个体保存	9
2.2.4 自适应概率机制	9
2.2.5 多重收敛原则	10
3 模型建立	10
3.1 数据选取	11
3.1.1 并联电容器组选取	11
3.1.2 分布式电源选取	12
3.2 目标函数	12
3.3 约束条件	13
3.4 建模仿真	13
4 结语	17
参考文献	18

基于改进遗传算法的含分布式电源电网无功优化

摘要

针对**分布式电源 (DG)** 接入导致配电网潮流分布与电压水平显著变化、传统无功优化方法难以兼顾离散控制与连续控制的工程问题, 本文以 IEEE33 节点配电网为算例, 构建含 DG 与并联电容器的无功优化模型。

以系统**有功网损与节点电压偏差**为核心指标, 建立综合目标函数并在潮流方程与 DG/无功补偿容量上下限约束下求解。为提升标准**遗传算法**在该类非线性、混合整数优化中的收敛效率与稳定性, 提出改进遗传算法: 采用**二进制-实数混合编码**描述电容器投切与无功出力, 构造基于群体极值的**自适应适应度**映射以增强个体区分度, 引入最优个体保留与移民策略以抑制早熟, 并设计**自适应交叉/变异概率**与“**多重收敛准则**”以降低无效迭代。仿真结果表明, 在相同目标函数与种群规模、最大迭代次数约束下, 改进算法相较标准遗传算法获得更小的全局最优目标函数值 (由 **9.115 降至 6.223**) 且收敛代数显著减少 (由 **40 代降至约 13 代**), 并使节点电压均满足运行范围要求。进一步比较显示, 两种算法在网损下降率与电压偏差量指标上差异不大, 但改进算法在寻优效率与全局最优解获取能力方面具有优势, 为含 DG 配电网无功优化提供了一种有效的智能求解途径。

关键字: 分布式电源 遗传算法 无功优化 人工智能

一、引言

1.1 研究背景与意义

随着传统能源的大量消耗, 能源枯竭问题日益凸显, 各国纷纷将开发和利用太阳能、风能等可再生能源作为重要的发展方向。利用清洁能源进行发电不仅能够有效缓解一次能源紧张、降低环境污染, 同时也促进了能源结构的优化与低碳化趋势的发展。然而, 分布式电源 (Distributed Generation, DG) 的大规模接入在为配电网带来经济性与可靠性收益的同时, 也对系统运行产生了多方面的影响。首先, DG 接入会改变原有配电网的潮流分布, 甚至导致潮流方向的反转, 从而影响系统的潮流特性; 其次, 潮流变化将直接改变配电网的网损水平, 使得系统损耗呈现新的分布规律; 此外, 功率电子接口的大量应用还会对电能质量造成不利影响, 如谐波注入、电压闪变等。因此, 为保证含分布式电源的配电网安全、稳定、高质量运行, 开展无功优化研究具有重要的工程意义。




图 1 无功优化工作图

1.2 研究现状

针对含 DG 配电网的无功优化问题，现阶段主要研究途径分为两类：一类是传统数学优化方法，如内点法、动态规划法以及混合整数规划等；另一类是人工智能优化方法，如粒子群算法、蚁群算法、蝙蝠算法等智能仿生算法。传统算法虽具有理论成熟、求解精确的优点，但对模型的线性化和凸性条件要求较高，难以处理配电网中强随机性与非线性的无功优化问题；而智能算法具备全局寻优能力强、对模型依赖性低等优势，但在求解过程中常面临收敛速度慢、易陷入局部最优等问题。

配电网无功优化问题经过多年研究，求解方法可以分为传统优化算法和人工智能算法两种。传统优化算法有线性规划法、混合整数法、动态规划法等；人工智能算法有遗传算法、粒子群算法、蝙蝠算法、鲸鱼算法等。传统优化算法本质上属于数学算法，在求解过程中，需要先给定初值，然后根据目标函数和约束条件进行迭代，最后得出结果。

（1）线性规划法（Linear Programming, LP）

线性规划法的本质是把目标函数和约束条件非线性转化为线性。线性规划法简单、收敛性强，适用于解决约束条件多的优化的问题。线性规划法的局限在于在将非线性问题转换成线性问题的后会出现较大的误差，这限制了线性规划法的使用^[1]。

（2）非线性规划法（Non-Linear Programming, NLP）

非线性规划法的原理是利用拉格朗日乘子法或惩罚函数,将目标函数转化为一个增广的目标函数。非线性规划算法具有收敛性强,收敛速度快的优点,但是当求解有多个约束条件的非线性问题时,会出现计算量大的缺点;如果目标函数中包含惩罚函数,并且惩罚函数选择不合适,会导致算法的收敛性变差,严重影响最后收敛结果^[2]。

(3) 混合整数法 (Mixed-Integer Programming, MIP)

混合整数法先将约束条件中的离散变量与连续变量分离,再将两个变量分别处理。这种方法收敛精度高,但是随着维度的增加,计算时间也随之增加,因此该方法不适合求解复杂、规模大的系统^[3]。

综上,在某些方面传统优化算法具有一定的优势,但是也存在一些不可忽略的弊端。传统优化算法弊端有:

(1) 对于数学模型要求高,如果数学模型不能够满足一定的条件,有可能出现无法收敛或者收敛结果差的现象;

(2) 对初值的选取严格,若初值选取不当,会出现陷入局部最优的情况,最后得不到最优解;

(3) 传统优化方法对于求解结构复杂、规模大的系统,会出现运算复杂、求解时间长的问题。

1.3 人工智能算法

我国的配电网系统呈现越来越复杂和规模越来越大的现象,使用传统优化方法求解含分布式电源配电网无功优化的弊端越来越显著。随着计算机技术的发展,人工智能算法的使用和普及越来越广泛,开始有学者使用人工智能算法用于求解含分布式电源配电网无功优化问题。

(1) 粒子群算法 (Particle Swarm Optimization, PSO)

粒子群算法模拟了鸟群觅食行为。该算法的优点是求解过程简单,准确度高,同时算法也有易陷入局部最优的缺点。文献^[4]针对算法的不足,引入惯性权重和阈值来增强搜寻全局最优解法的能力,通过仿真,证明了改进粒子群算法的缺陷得到了改善,并证明了改进粒子群算法能够求解配电网无功优化问题。

(3) 遗传算法 (Genetic Algorithm, GA)

遗传算法是模拟生物的遗传和演化。算法寻优能力强,可以自由调整搜索方向,但是标准遗传算法易早熟和后期收敛速度慢。文献^[5]引入自适应对偶种群、自适应终止条件和新的子代生成条件,防止算法早熟和提高算法的收敛速度,通过仿真证明了改进算法具有较好的稳定性,不易陷入局部最优。

(3) 鲸鱼算法 (Whale Optimization Algorithm, WOA)

鲸鱼算法模拟鲸鱼捕食行为,具有操作简单、参数少、易跳出局部最优的优点,但是标准鲸鱼算法收敛速度较慢,收敛精度低。文献^[6]通过引入细胞膜优化算法的浓度划分机制和混沌映射来改进鲸鱼算法,提高鲸鱼算法的搜索速度和精度,通过仿真,证明了改进鲸鱼算法优于标准鲸鱼算法,对于求解无功优化问题更加高效。

分布式电源接入配网面临的另一个问题是：分布式电源的输出受到多个不可控因素的影响，其出力状况具有大的随机性和波动性。如何在这种情况下对配电网进行无功优化是一个新的难题和研究方向。

对于分布式电源输出不确定性的特点，常用的处理分布式电源不确定性的方法有：鲁棒优化法、情景分析法、分时段优化法、机会约束规划法等。经过多年研究，研究人员将四种处理方法和人工智能算法相结合，用来求解含分布式电源配电网动态无功优化研究。

基于此，本文采用自适应遗传算法（Genetic Algorithm, GA）来求解含分布式电源的配电网无功优化问题。遗传算法作为一种典型的智能进化算法，通过选择、交叉和变异等操作模拟自然进化过程，具有较好的全局搜索能力和适应复杂系统的优势。针对传统遗传算法在收敛性能和寻优效率方面的不足，本文在基础遗传策略上进行改进，包括优化编码方式、引入自适应概率机制等，以提升算法的收敛速度和求解精度。最后，采用改进遗传算法、标准遗传算法对 IEEE33 节点含分布式电源配电网进行无功优化仿真，并对比分析两种算法的优化效果，以验证所提方法的有效性。

二、模型介绍

2.1 传统遗传算法

遗传算法（Genetic Algorithm, GA）是一种基于自然选择与遗传机理的全局随机优化方法，通过对解空间中候选解的编码表示与群体进化，实现对目标函数的逐步逼近优化。在含分布式电源配电网无功优化问题中，遗传算法通过对无功补偿量、节点电压控制量等决策变量进行编码，以种群形式在可行解空间中搜索，使系统网损、电压偏差等性能指标逐步优化收敛。

2.1.1 进行问题编码

首先，需要对无功优化问题进行合理的变量编码。设待优化决策变量向量为 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ ，其中可包含无功补偿容量、分布式电源的无功出力以及部分电压控制变量。遗传算法通过预先设定的编码规则，将连续或离散的物理量映射为染色体结构。常见的编码方式包括二进制编码与实数编码：前者利用 0/1 串表示变量取值区间内的离散点，结构清晰、易于实现；后者直接以实数作为基因，能更精细地刻画连续变量，提高寻优精度和收敛效率。编码方案应保证每个染色体对应于优化模型中的一个可行解，且便于后续遗传操作的实现。

2.1.2 构造初始种群

在编码规则确定后，构造初始种群。设种群规模为 N ，则可通过随机方式在变量允许范围内生成 N 个个体，每个个体为一个完整染色体，表示一组候选无功优化方案。为了提高搜索的多样性与全局性，初始种群应在解空间内尽可能均匀分布，避免个体过于集中于局部区域。同时，在工程应用中可以根据经验解或已有优化结果，适当引入少量

具有较好性能的个体，以提高算法初始解的质量，但必须保证整体种群仍具有足够的多样性。

2.1.3 建立适应度函数

随后，需要构建适应度函数，对种群中每个个体的优劣进行量化评价。设无功优化的目标函数为 $F(x)$ ，例如可以将网损 P_{loss} 最小化，或者采用综合目标函数，如：

$$F(x) = \alpha P_{\text{loss}} + \beta \sum_i (V_i - 1.0) + \gamma Q_{\text{cost}} \quad (1)$$

其中 α 、 β 、 γ 为权重系数， V_i 为第 i 个节点电压幅值， Q_{cost} 为无功补偿成本。在此基础上定义适应度函数 $\text{fit}(x)$ ，其形式可为 $\text{fit}(x) = 1 / (1 + F(x))$ 或其他单调变换，使得目标函数值较小的个体对应更大的适应度值。对于违反电压约束、功率约束或设备容量约束的解，可通过罚函数方式在目标函数中引入惩罚项，从而降低其适应度，保证最终解满足工程约束条件。

2.1.4 执行选择、交叉、变异操作

在完成适应度评价后，进行选择操作以实现“优胜劣汰”。选择算子按照个体适应度大小，赋予适应度较高个体更高的遗传概率，从而增加其进入下一代种群的机会。常用策略包括轮盘赌选择和锦标赛选择等。以轮盘赌选择为例，设第 k 个个体的适应度为 fit_k ，则其被选中的概率可定义为 $p_k = \text{fit}_k / \sum_j \text{fit}_j$ 。通过该方式，可以在保持种群多样性的同时，逐步提高优秀基因在种群中的比例，引导搜索过程向更优解区域推进。

在选择操作之后，对选出的个体实施交叉操作，以形成新的后代个体。交叉算子通过对两个“父代”染色体的基因片段进行交换，产生新的“子代”染色体，旨在组合与重组不同个体的优良基因。设交叉概率为 P_c ，当随机数 $r \in [0,1]$ 满足 $r \leq P_c$ 时，对成对个体执行交叉操作。具体交叉方式可根据编码类型选择：在二进制编码场景下，可采用单点交叉或多点交叉；在实数编码场景下，可采用算术交叉或模拟二进制交叉等。合理的交叉策略有助于增强算法的全局搜索能力，加速种群向高适应度区域收敛。

变异操作是保持种群多样性、防止算法早熟收敛的重要环节。在交叉生成子代后，对其染色体以变异概率 P_m 执行基因扰动。对二进制编码而言，变异通常表现为对某些基因位进行“0 $\leftrightarrow$ 1”的翻转；对实数编码而言，变异则通过在基因值上叠加小幅随机扰动或采用非均匀变异策略实现。通过适度的变异操作，可以使种群跳出局部最优解附近的小区域，增强搜索的探索性，但过大的变异概率又会导致搜索过程过于随机，甚至破坏已积累的优良基因。因此， P_m 的设定需要在探索能力与收敛稳定性之间进行平衡。

2.1.5 更新种群并迭代

完成选择、交叉与变异操作后，需要更新种群，形成新一代候选解集合。常见更新策略包括完全替代和精英保留等。完全替代策略直接使用新生成的子代个体替换上一代种群；精英保留策略则在每一代中保留若干适应度最高的个体直接进入下一代，以避免在遗传操作过程中丢失当前的最优解。实践表明，引入精英保留机制可以显著提高算法的稳定性与收敛性能，是工程应用中较为常用的改进措施。

最后，需要设定合理的终止判据以结束迭代过程。常用的终止条件包括：达到最大迭代代数 G_max ；连续若干代中群体最优适应度提升幅度低于预设阈值 ϵ ，即算法已基本收敛；或者适应度达到预先给定的目标水平。当满足终止条件时，种群中适应度最高的个体所对应的染色体解即视为无功优化问题的优化结果。通过上述编码、初始化、适应度评价、遗传操作与终止判据等步骤，遗传算法能够在复杂的含分布式电源配电网无功优化问题中实现较为有效的全局寻优。




图 2 程序流程图

2.2 改进遗传算法

传统的遗传算法虽然具备适应性强，易于并行，种群中交换信息以及全局随机搜索等特点，但是仍有收敛速度较慢，迭代解不稳定等缺点。因此本文在传统的遗传算法的基础上，对算法的编码，适应值计算以及选择、交叉、变异及迭代终止值判断上进行改进，以提升算法的收敛速度和求解精度。

2.2.1 混合编码

考虑本文需要求解分布式发电的系统无功优化问题，变量数量较多、含有连续变量、精度要求高等情况存在，而二进制编码后的染色体串长度会随着变量增多而大幅度增长，计算难度将大大提高。并且二进制编码的 0、1 字符本身只具有离散性，不能合理的表示连续变量，其编码解码的过程将带来较大的误差，不符合优化问题的要求。综合以上几点，研究分布式发电系统无功优化问题时，由二进制编码和实数编码组成的混合编码是最为可行的。

本文将分布式电容数量按照二进制编码，而无功补偿容量按照实数编码，将两种编码方式相结合，形成混合编码。其中，二进制编码的染色体串长度为 n ，实数编码的染色体串长度为 m ，则整个染色体串的长度为 $n+m$ 。二进制编码的染色体串用于表示分布式电容的投切状态，实数编码的染色体串用于表示分布式电容的无功补偿容量。

2.2.2 适应度函数改进

为了增强种群的对比性，考虑到当代最优和最劣的个体加入到和目标个体的比较中，并且使得适应度函数随着每代种群的进化逐步进行自我调整适应——当某个个体的目标函数值越大，其相应的适应度函数值就会越小，进化结果越好：

$$F^* = \frac{F_{\max} - F_i}{F_{\max} - F_{\min} + \gamma} + \frac{F_{\max} - F_{\min}}{F_i - F_{\min} + \gamma} \quad (2)$$

其中， $F_{\max}$ 为种群中目标函数的最大值， $F_{\min}$ 为种群中目标函数的最小值， F_i 为种群中第 i 个个体的目标函数值， γ 为一个很小的正数，用于防止分母为零。

2.2.3 最优个体保存

遗传算法的计算过程中虽然表现优秀的个体会越来越多，但是由于 每代交叉、变异操作是概率性选取的个体，随机度较高并且适应度值高的个体也有可能被挑选出来进行交叉、变异，优秀性状被破坏，这无疑将降低算法收敛的速度甚至使得算法不再收敛。所以，考虑到算法的计算速度以及对最优个体的保护，引入最优个体保存法，用部分最优个体取缔相同数量的最差个体（为了不让种群基因重合度过高并保持种群性状的多样性，此部分个体数量占比不宜超过 5%）。与此同时，为了避免算法早熟，引入“移民政策”，即当种群最优适应度值遗传多代并无变动时，随机投入一定数量个体代替最差个体。

2.2.4 自适应概率机制

对均匀交叉进行改进，以不完全均匀交叉方式并综合禁止近亲 结合机制来对父代个体进行交叉操作，即首先将两个个体码串的一半当作一个极值，当两个体间的“海明距离”（相应部分特征值不相同的位数）低于此极值时，则定义为近亲，不考虑进行交叉；反之，若个体特征值不同的位数为 n ，选出 $n/2$ 个字符，并以自适应交叉概率进行交叉互换。从当前国内外对遗传算法的研究来看，被广泛使用的自适应交叉概率一般形式如下所示：

$$P_c = \begin{cases} \frac{(P_{c\max} - P_{c\min})(f_i - f_{\min})}{f_{\max} - f_{\min}} & f_i \geq f_{\text{avg}} \\ P_{c\min} & f_i < f_{\text{avg}} \end{cases} \quad (3)$$

其中， P_c 为交叉概率， $P_{c\max}$ 和 $P_{c\min}$ 分别为交叉概率的上限和下限， f_i 为个体 i 的适应度值， $f_{\min}$ 和 $f_{\max}$ 分别为种群中适应度最小值和最大值， f_{avg} 为种群中适应度平均值。

自适应变异概率如下：

$$P_m = \begin{cases} \frac{(P_{m\max} - P_{m\min})(f_{\max} - f_m)}{f_{\max} - f_{\min}} & f_m \geq f_{\text{avg}} \\ P_{m\min} & f_m < f_{\text{avg}} \end{cases} \quad (4)$$

其中, P_m 为变异概率, $P_{\max}$ 和 $P_{\min}$ 分别为变异概率的上限和下限, f_m 为个体 m 的适应度值, $f_{\min}$ 和 $f_{\max}$ 分别为种群中适应度最小值和最大值, f_{avg} 为种群中适应度平均值。

2.2.5 多重收敛原则

传统遗传算法的收敛条件设定较简单,即进化到最大代数时算法停运。这种方法虽然简单方便,但是影响算法计算时间,降低了算法效率,增加了数据存储的空间。综合多次预实验证明,本文设置“三重收敛准则”:第一,进化达到最大代数(此处为 40),算法终止;第二,当进化到一定程度,每代最优适应度指标差值变化不大时,即遗传算法连续多代的最优解差值小于终止指数 ε (约为 0.00001),算法终止;第三,当某代个体的适应度指标不大于预设优化的最小值(综合算法运行参数统计,约为初代适应度最优值的 10%),算法终止。若是满足三条准则中的任意一条,则算法不再运行;若是均不满足,则算法继续。

总的来说,传统遗传算法比较简单,但是效率和精确度都达不到要求;而一般性的改进遗传算法,只是简单考虑自适应交叉变异的问题,对编码、适应度函数、种群的初步筛选以及算法收敛等问题均不曾解决。而本文设计的自适应遗传算法对问题的分析以及计算过程都有明显的优化,并且更适合求解多目标、多约束的复杂函数问题,在计算效率上也有一定的改进,节省数据空间,更易求得最优解。同时自适应遗传算法还能防止过早收敛,取得全局最优解,其流程总结如下:




图 3 程序流程图

三、模型建立

3.1 数据选取

随着电网结构不断复杂,如果每个点都安装无功补偿装置花销太大,因此,需要在配电网中合适的位置安装无功补偿装置。在合理的地点安装无功补偿装置可以有效的减少配电网系统中无功功率的流动,降低系统的损耗。本文采用无功裕度法确定无功补偿装置(并联电容器组)安装位置。并采用 IEEE33 节点配电网作为算例,配电网结构图如下图所示:




图 4 IEEE33 节点配电网结构图

3.1.1 并联电容器组选取

无功裕度法是从数值分析的角度反映了电网当前运行状态和电网极限状态的差距,并借此反映电网节点电压的稳定程度^[7]。选取配电网系统一条支路,该支路的结构图如下图所示:




图 5 程序流程图

线路的导纳为 $g + jb$,无功裕度法的方法为:

$$Q_{yd} = r_P + r_Q - D \quad (5)$$

其中, r_P , r_Q 和 D 分别为:

$$\begin{cases} r_P = \sqrt{\frac{U_0^2}{4} + \frac{b^2 U_0^2}{4g^2} - \frac{P_1}{g}} \\ r_Q = \sqrt{\frac{U_0^2}{4} + \frac{g^2 U_0^2}{4g^2} - \frac{Q_1}{g}} \\ D = U_0 \frac{g^2 + b^2}{2gb} \end{cases} \quad (6)$$

节点 i 处的等效无功裕度为:

$$Q_{ydi} = \sum_{j=1}^{N_i} (r_{Pji} + r_{Qji} - D_j) \quad (7)$$

综上所述,通过各节点的无功裕度值大小即可判断需要在哪些节点 接入无功补偿装置。无功裕度越小,代表无功缺额较大,应补偿的无功量越大;无功裕度越大,代表无功缺额较小,应补偿的无功量也就越小。

根据无功裕度值的计算方法以及通过潮流计算结果,得到各节点无功裕度值分布如下表:




图 6 IEEE33 节点无功裕度值分布图

根据表格中数据及分布图易得,9 号节点与 30 号节点无功裕度值较低,需要进行无功补偿。

3.1.2 分布式电源选取

通过分析分布式电源接入位置对配电网系统有功功率损耗和节点电压的影响可以得出,当分布式电源接入配电网时,应该合理的选择接入位置;当分布式电源接入配电网系统主支路节点时,应当选择远离电源节点位置,例如 15-17 号节点;当分布式电源接入配电网系统辅支路节点时,应当选择 30-33 号节点。

3.2 目标函数

配电网无功优化问题常见的目标函数分为以下几种:

- (1) 以系统有功功率损耗最小为目标函数

分布式电源接入配电网后,会改变系统的功率分布,因此分布式电源接入配电网会对系统的有功功率损耗产生一定的影响。减小配电网系统的有功功率损耗可以提高系统运行的经济性。以配电网有功功率损耗最小为目标函数的表达式为:

$$\min f_1 = \sum_{i,j \in N} G_{ij}(U_i^2 + U_j^2 - 2U_i U_j \cos(\theta_i - \theta_j)) \quad (8)$$

式中，N 是配电网系统节点数； U_i 和 U_j 分别是第 i 个节点和第 j 个节点的电压； G_{ij} 是第 i 个节点与第 j 个节点之间支路电导； θ_{ij} 是第 i 个与第 j 个节点相角的差值。

(2) 以节点电压偏差值最小为目标函数

随着社会的不断发展，各种用电设备对于电能质量的要求越来越高，电压偏差是衡量电能质量的标准之一。系统的无功功率分布能够影响系统电压水平，系统无功功率是否充足，会导致系统的电压增加或者降低。当系统电压低于或者超过界限值后，会影响各种用电设备的使用情况，例如，降低产品质量、缩短设备使用时间等，给企业造成巨大的损失。

以节点电压偏差值最小为目标函数的表达式为：

$$\min f_2 = \min \sum_{i=1}^N \left| \frac{U_i - U_{\{i,\text{ref}\}}}{U_i^{\max} - U_i^{\min}} \right| \quad (9)$$

$$U_{i,\text{ref}} = \frac{U_i^{\max} + U_i^{\min}}{2} \quad (10)$$

(3) 以投资最小为目标函数

当系统的无功功率不足时，需要对系统进行无功补偿，安装无功补偿装备需要考虑设备的安装成本。

以无功补偿设备投资最小为目标函数的表达式为：

$$\min f_3 = \sum_{i=1}^N C_i Q_i \quad (11)$$

式中，i 是安装无功补偿装置的节点数； C_i 是节点 i 无功补偿装置设备单位容量投资； Q_i 是节点 i 无功补偿装置实际投入量。

3.3 约束条件

含分布式电源的配电网进行无功优化的等式约束条件为配电网系统的潮流方程：

$$P_i + P_{\text{DG}i} = P_{Di} + U_i \sum_{j \in N} U_j (G_{ij} \cos(\theta_i - \theta_j) + B_{ij} \sin(\theta_i - \theta_j)) \quad (12)$$

$$Q_i + Q_{\text{DG}i} = Q_{Di} - U_i \sum_{j \in N} U_j (G_{ij} \sin(\theta_i - \theta_j) - B_{ij} \cos(\theta_i - \theta_j)) \quad (13)$$

式中， P_i 和 Q_i 是节点 i 处由配电网输入的有功功率和无功功率； $P_{\text{DG}i}$ 和 $Q_{\text{DG}i}$ 是由分布式电源注入的有功功率和无功功率； P_{Di} 和 Q_{Di} 是负荷的有功功率和无功功率； Q_{Ci} 是无功补偿装置提供的无功功率； B_{ij} 是节点 i 和节点 j 之间支路的电纳。

3.4 建模仿真

本文的目标函数主要选取有功功率损耗最小和节点电压偏差值最小，基于此构建数学模型。

目标函数：

$$\min f = \lambda P_{\text{loss}} + U_d + f_{\text{cost}} \quad (14)$$

约束：

$$\begin{cases} Q_{\text{Di},\min} \leq Q_{\text{Di}} \leq Q_{\text{Di},\max} & i = 1 \dots N_D \\ Q_{\text{Ci},\min} \leq Q_{\text{Ci}} \leq Q_{\text{Ci},\max} & i = 1 \dots N_C \end{cases} \quad (15)$$

其中， N_D 与 N_C 分别为分布式电源节点数和无功补偿节点数， $Q_{\text{Di},\min}$ 与 $Q_{\text{Di},\max}$ 分别为分布式电源节点 i 的无功功率下限与上限， $Q_{\text{Ci},\min}$ 与 $Q_{\text{Ci},\max}$ 分别为无功补偿节点 i 的无功功率下限与上限。

根据数据选取的分析，本文在 IEEE33 节点的基础上，安装 2 个分布式电源与 2 个并联电容器组。把 2 个分布式电源分别安装在节点 16 和节点 33，2 个并联电容器组分别安装在节点 9 和节点 30^[8]。

表 1 分布式电源数据

	节点编号	最大有功功率(KW)	最大无功功率(KVar)
DG1	16	500	500
DG2	33	500	500

表 2 并联电容器数据

	节点编号	安装组数	单个容量
C1	9	10	100
C2	30	10	100

安装后的 IEEE33 结构图如下所示：




图 7 安装无功补偿装置后的 IEEE33 节点配电网结构图

将传统遗传算法、改进遗传算法分别对安装后的配电网进行无功优化，得到迭代曲线如下所示：




图 8 传统遗传算法迭代曲线




图 9 改进遗传算法迭代曲线

在两种算法目标函数、最大迭代次数和种群个数相同的情况下，可以明显看出改进后的遗传算法收敛速度更快，且目标函数值更小，说明多收敛原则在其中发挥了作用，提高了效率，使得改进后的遗传算法在配电网无功优化中具有更好的性能。

从全局最佳值上来看，传统遗传算法和改进遗传算法的最终结果分别为 9.115 和 6.223，从各代平均值上来看，传统遗传算法收敛后达到 9.5 左右的函数值，而改进后的遗传算法在 10.0 附近左右，说明改进后的遗传算法在找出最优解上明显效率更高，但是对于个代平均值的搜索迭代上，由于收敛迭代次数的约束，与传统遗传算法有些差别。

将传统遗传算法、改进遗传算法分别对安装后的配电网进行无功优化，得到节点电压对比图如下所示：




图 10 传统遗传算法节点电压优化前后对比




图 11 改进遗传算法节点电压优化前后对比

当配电网没有接入分布式电源时，原配电网系统的电压水平较低，共有 21 个节点的电压幅值低于规定水平，节点电压达到标准的只有 12 个，只占总数的 36.4%，节点电压不合格率高达 63.6%，其中 18 号节点的电压幅值最低，接入分布式电源后，配电网节点电压得到提升，均超过规定最小值；当使用传统遗传算法和改进遗传算法进行优化后，配电网系统 33 个节点的电压幅值均在规定的范围之内，其中，改进遗传算法使得配电网系统的每个节点电压提升水平要高于传统遗传算法。

标准遗传算法和改进遗传算法分别对配电网系统进行无功优化后，并联电容器组和分布式电源的无功出力情况如下表所示。

表 3 无功出力

	C1/kVar	C2/kVar	DG1/kVar	DG2/kVar
传统遗传算法	100	200	399.63	392.82
改进遗传算法	0	0	318.91	471.34

表 4 网损及电压偏差

	优化前网损	优化后网损	网损下降率	节点电压偏差量
传统遗传算法	0.20	0.06	69.35%	0.77
改进遗传算法	0.20	0.07	67.06%	0.77

经过对比可以得到,在传统遗传算法的优化下,DG1 出功多于改进遗传算法,而 DG2 出功少于改进遗传算法,说明两种算法对不同节点的优化效果不同,在优化分布式电源出力上,改进遗传算法具有更好的性能。

对于网损和电压偏差量,两种算法的优化效果相差不大。




图 12 节点电压变化量

上图为改进后的遗传算法在节点电压上的变化量,从图中可以看出,在优化前,节点电压偏差量较大,优化后,节点电压偏差量平均减小 50% 左右,说明改进后的遗传算法在节点电压优化上具有较好的性能。

四、结语

本文围绕含 DG 配电网的无功优化问题,建立了以网损与节点电压偏差为核心的综合优化模型,并在潮流等式约束与设备容量约束下,对 DG 无功出力与并联电容器投切进行协同优化。针对标准遗传算法在混合离散-连续变量、强非线性潮流约束下易出现早熟与后期收敛缓慢的问题,提出并实现了一种改进遗传算法:通过混合编码降低编码误差并适配不同类型控制变量;通过基于群体极值的适应度映射提升个体比较尺度一致

性；通过最优保存与移民机制在保持优秀基因的同时维持种群多样性；并利用自适应交叉/变异概率与多重收敛准则减少冗余迭代，从而提高求解效率。

IEEE33 节点算例验证表明，所提改进算法在相同计算配置下能够以更少迭代代数获得更优的综合目标函数值；在电压约束方面，优化后各节点电压均满足允许范围，节点电压偏差显著降低；在网损指标方面，优化前后网损均得到有效削减。对比分析显示，改进算法相较标准遗传算法更易获得更小的全局最优目标函数值，体现出更高的寻优效率与一定的鲁棒性；但在网损下降率与电压偏差量等单项指标上，两者改善幅度接近，说明在既定算例与权重设置下，综合目标的改进主要来源于全局最优解搜索效率的提升。

后续工作可从以下方向进一步深化：其一，引入 DG 出力不确定性与负荷波动，采用情景法或机会约束形式建立动态无功优化模型；其二，将电容器投切成本、开关动作次数与电压越限风险等运行经济性与安全性指标纳入多目标框架，并采用帕累托优化获得折中解集；其三，结合配电网拓扑与时序运行数据对权重系数与惩罚项进行系统辨识与敏感性分析，以增强模型参数的工程可解释性与适用性。

参考文献

- [1] 杨成. 基于深度差分进化的电力系统无功优化研究[J]. 2021.
- [2] 王克文, 赵晓铎, 刘晓峰. 基于单纯形法思想的城市高压电网非线性无功优化[J]. 郑州大学学报(工学版), 2010: 95-98.
- [3] 张昕. 基于群智能优化算法的电力系统无功优化研究[J]. 福建工程学院, 2022.
- [4] 高金兰, 雷星雨, 朱佳丽. 动态改变惯性权重的伪梯度搜索粒子群算法在无功优化中的应用[J]. 化工自动化及仪表, 2018: 35-40.
- [5] 刘永江, 陈昊. 电力配网系统无功优化方法研究[J]. 现代电子技术, 2016, 39.
- [6] 孙琪, 于永进, 王玉彬等. 采用改进鲸鱼算法的配电网综合优化[J]. 电力系统及其自动化学报, 2021: 22-29.
- [7] 李澎. 含分布式电源的电力系统无功优化[J]. 湖南大学, 2020.
- [8] 张高帅. 含分布式电源配电网无功优化研究[J]. 兰州理工大学, 2023.